

# Tirocinio su Posit

Luigi Leonardi

## Indice

<b>1</b>	<b>Introduzione</b>	<b>3</b>
1.1	Posit . . . . .	3
1.2	Note sui Test . . . . .	3
<b>2</b>	<b>Test su Moltiplicazione</b>	<b>4</b>
2.1	Accuratezza . . . . .	4
2.1.1	Svolgimento . . . . .	4
2.1.2	Conclusioni . . . . .	4
2.1.3	Codice . . . . .	5
2.2	Tempi . . . . .	6
2.2.1	Svolgimento . . . . .	6
2.2.2	Conclusioni . . . . .	6
2.2.3	Codice . . . . .	7
<b>3</b>	<b>Test su Sigmoide</b>	<b>8</b>
3.1	Introduzione . . . . .	8
3.2	Accuratezza . . . . .	8
3.2.1	Svolgimento . . . . .	8
3.2.2	Conclusioni . . . . .	9
3.2.3	Codice . . . . .	9
3.3	Tempi . . . . .	11
3.3.1	Parte 1 . . . . .	11
3.3.2	Parte 1 - Esito . . . . .	12
3.3.3	Parte 2 . . . . .	12
3.3.4	Parte 2 - Esito . . . . .	12
3.3.5	Parte 3 . . . . .	12
3.3.6	Parte 3 - Esito . . . . .	12
3.3.7	Codice . . . . .	13
3.4	Conclusioni . . . . .	14

<b>4</b>	<b>Divisione e Moltiplicazione mediante regime</b>	<b>15</b>
4.1	Introduzione . . . . .	15
4.2	Accuratezza . . . . .	15
4.2.1	Risultati . . . . .	15
4.3	Tempi . . . . .	15
4.3.1	Risultati . . . . .	15
4.3.2	Codice . . . . .	16
<b>5</b>	<b>Conclusioni</b>	<b>17</b>

# 1 Introduzione

## 1.1 Posit

Il Posit è un formato di numero in virgola mobile ideato da John Gustafson, in alternativa allo standard IEEE 754. L'idea di base è fondamentalmente la stessa, anche nei Posit è presente un bit per il segno, dei bit per l'esponente e dei bit per la mantissa, le principali differenze consistono nella presenza di un "super esponente" o regime e nel non avere un numero di bit fissato per quest'ultimo e per la mantissa.

Il vantaggio nell'avere un super esponente, la cui lunghezza non è definita,




Figura 1: "Formato Posit"

permette di ottenere un range di numeri molto più flessibile, il suo contributo è pari a  $2^{2^{es}}$  con  $es$  il numero di bit dell'esponente<sup>1</sup>, permettendo ad esempio una riduzione del numero di bit assegnati a quest'ultimo campo. Questi bit di regime non sono altro che una sequenza di cifre binarie identiche, terminate dal complemento di esse.

Ad esempio: 0001 rappresenta -3, dove 3 è il numero degli 0 ed 1 è il terminatore.<sup>2</sup>

Non sono inoltre previsti overflow e underflow o la rappresentazione di NaN.

## 1.2 Note sui Test

Tutti i test svolti sui Posit sono stati effettuati sfruttando la libreria in C++ BFP[1] implementando, dove necessario, le funzionalità mancanti.

I Posit scelti sono stati a 32/64 bit, con 0 bit di esponente<sup>3</sup>, dove non specificato diversamente.

<sup>1</sup>L'esponente è l'unico campo ad avere una dimensione fissa

<sup>2</sup>Regimi che iniziano per 0 sono negativi, per 1 invece sono positivi. Lo 0 è rappresentato come 10

<sup>3</sup>Ha senso non utilizzare bit di esponente, in quanto si sfrutta il super esponente

## 2 Test su Moltiplicazione

### 2.1 Accuratezza

Questo test vuole dimostrare che a parità di bit utilizzati, 32 in questo caso, i Posit risultano essere più precisi nel rappresentare i risultati di prodotti, rispetto ad un Float a 32 bit.

In questo particolare caso sono stati impiegati Posit [32,3], ossia 32 bit totali, di cui 3 di esponente.

#### 2.1.1 Svolgimento

Il test consiste nel creare 9 array, 6 per gli operandi e 3 per i risultati, di una dimensione compresa nell'ordine dei milioni:

- 3 di Posit [32,3]
- 3 di Float a 32 bit
- 3 di Double a 64 bit come riferimento

Il passo successivo consiste nel popolare gli array degli operandi, operazione che viene svolta partendo dai Double sfruttando una funzione che genera dei numeri in modo pseudo-casuale, per poi provvedere a riempire gli altri semplicemente operando le necessarie conversioni.

Successivamente sono state eseguiti i vari prodotti i cui risultati sono stati collocati nel terzo array di ciascun tipo. Infine, per poter confrontare il tutto, i risultati sono stati riportati in Double e ne è stata fatta la differenza, in modulo, rispetto al riferimento.

Definisco:

$$\begin{aligned}\Delta_i(\text{Posit}) &= |\text{PositRes}_i - \text{DoubleRes}_i| \\ \Delta_i(\text{Float}) &= |\text{FloatRes}_i - \text{DoubleRes}_i|\end{aligned}$$

Dove FloatRes e PositRes sono il risultato del prodotto, fra Float e Posit rispettivamente, convertiti in double.

Se  $\Delta_i(\text{Posit}) < \Delta_i(\text{Float})$  i Posit sono più precisi dei Float per questo indice.

Se  $\Delta_i(\text{Posit}) > \Delta_i(\text{Float})$  i Float sono più precisi dei Posit per questo indice.

#### 2.1.2 Conclusioni

Dai risultati dei test svolti, i Posit si sono rivelati essere più precisi dei Float nel  $\approx 56\%$  dei casi. Sono risultati pari merito nel  $\approx 16\%$  dei casi.

I risultati risultano essere in linea con le aspettative, in quanto una maggiore precisione, a parità di dimensione, è imputabile ad un numero maggiore di bit disponibili per la mantissa, rispetto ai Float.

### 2.1.3 Codice

```
1 //Funzione per Numeri Random
2 double generateNumber(){
3     double tmp = (double)rand()/(double)RAND_MAX;
4
5     return (tmp*2000);
6 }
```

## 2.2 Tempi

Lo scopo di questo test è incentrato sul capire se, oltre ad esservi dei vantaggi a livello di precisione, vi sono dei vantaggi a livello di prestazioni nell'eseguire moltiplicazioni.

I Posit utilizzati sono del tipo [32-3].

### 2.2.1 Svolgimento

Per poter effettuare dei test che non avvantaggiassero i Float, sfruttando supporto hardware, è stata sfruttata la libreria SoftFloat[2] la quale implementa i Float interamente via software.

Lo svolgimento del test è simile al precedente, vengono creati 6 array di dimensione nell'ordine dei milioni

- 2 di Float
- 2 di SoftFloat a 32 bit
- 2 di Posit[32,3]

I primi due vengono popolati con numeri generati in modo pseudo-casuale, mentre i rimanenti 4 vengono riempiti convertendo, nei rispettivi formati, i numeri ottenuti precedentemente. Per poter ottenere i tempi è stata sfruttata la funzione `clock_gettime()`, la quale restituisce il timestamp di sistema. Salvando il timestamp ad inizio e fine elaborazione, durante il quale vengono eseguite le moltiplicazioni fra i due array, si riescono ad ottenere per differenza i tempi di lavoro per ciascun tipo di numero.

### 2.2.2 Conclusioni

Come potevamo aspettarci i Float con supporto hardware, sono stati  $\approx 11$  volte più veloci dei SoftFloat o dei Posit. Per quanto riguarda i Posit invece, sono stati più lenti di  $\approx 2$  volte rispetto ai SoftFloat. Anche questo risultato era prevedibile, in quanto i Posit non sono altro che una generalizzazione dei Float, avendo aggiunto dei campi a lunghezza variabile.

### 2.2.3 Codice

```
1 //Funzione per calcolo tempi Posit
2 double doTestPosit(unsigned int *X,unsigned int *Y,unsigned long n)
3 {
4
5     auto p1 = Posit(32, 3);
6     auto p2 = Posit(32, 3);
7
8     timespec start, stop;
9
10    clock_gettime( CLOCK_REALTIME, &start);
11
12    for(unsigned long i=0;i<n;i++){
13        p1.setBits(X[i]);
14        p2.setBits(Y[i]);
15
16        p1.mul(p2);
17    }
18
19    clock_gettime( CLOCK_REALTIME, &stop);
20
21    double res = BILLION*( stop.tv_sec - start.tv_sec ) +
22    ( stop.tv_nsec - start.tv_nsec );
23
24    return res;
25
26 }
```

## 3 Test su Sigmoide

### 3.1 Introduzione

Una caratteristica dei Posit con 0 bit di esponente, come osservato da Isaac Yonemoto, è che risulta molto facile e conveniente, a livello computazionale, calcolare la funzione sigmoidea, infatti bastano dei semplici shift e not. Essa trova largo impiego nell'ambito delle reti neurali e machine learning.

Per poter eseguire i seguenti test, è stato necessario implementare una funzione di conversione da Posit[32-0] a Float, in quanto la libreria ne risulta essere sprovvista.

### 3.2 Accuratezza

Il primo test che sono andato ad eseguire è stato di tipo numerico, ossia data la funzione  $f(x) = \frac{1}{1+e^{-x}}$ , ne ho confrontato i risultati con quelli restituiti dalla sigmoide ottenuta mediante manipolazione dei bit.

#### 3.2.1 Svolgimento

Per questo tipo di test ho generato un numero di Float, nell'ordine delle migliaia, in modo pseudo-casuale nel range -30 e 30, e ne ho calcolato la sigmoide sfruttando prima la funzione con l'esponenziale, e successivamente, dopo aver convertito il numero in Posit, l'altra. Infine ho plottato tutti i risultati su MatLab ed ho ottenuto il seguente grafico:




Figura 2: "Sigmoide"



### 3.2.2 Conclusioni

Come si può evincere dalla figura, il grafico ottenuto con i Posit sembra essere una spezzata che segue l'andamento della sigmoide con i Float, inoltre i due grafici si vanno a sovrapporre nell'origine. In generale comunque possiamo affermare che effettivamente questo tipo di manipolazione sui bit, ha fornito una approssimazione della sigmoide.

### 3.2.3 Codice

```
1 //Sigmoide con Float
2 float sigmoid(float &x){
3     return 1/(exp(-x)+1);
4 }
5
6 //Sigmoide con Posit
7 unsigned int sigmoid(unsigned int bits){
8     bits = bits ^ 0x80000000;
9     bits = bits >> 2;
10    return bits;
11 }
12
13
14 //Conversione da Posit[32-0] a Float
15 float Posit::subconv(){
16     union {
17         float f;
18         uint32_t bits;
19     };
20     bits=0;
21
22     if((mBits & 0xFFFFFFFF) == 0)
23         return 0.0f;
24     signed char c = (signed char)(regime());
25     c+= 127;
26     unsigned int esponente = (unsigned int)(c);
27
28     esponente = esponente<<23;
29     bits = bits | esponente;
30     unpacked_t aup = unpack_posit(mBits, mNbits, mEs);
31     unsigned int fr_ = aup.frac;
32
33     fr_ = fr_>>9;
34     bits = bits | fr_;
```

```
35     int segno = aup.neg;
36     if(segno == 0)
37         bits &= 0x7FFFFFFF;
38     else
39         bits |= 0x80000000;
40
41     return f;
42 }
```

### 3.3 Tempi

Una volta dimostrato che possiamo approssimare la sigmoide, il passo successivo è quello di provare che effettivamente vi sia un risparmio tangibile nell'eseguire i calcoli.

Questo test, suddiviso in più parti, effettua diversi confronti, sui tempi di elaborazione, fra sigmoide su Posit e sigmoide ottenuta in vari modi sui Float.

#### 3.3.1 Parte 1

Il primo confronto eseguito è stato con la funzione sigmoide esponenziale  $f(x) = \frac{1}{1+e^{-x}}$ , la stessa utilizzata nel test numerico.

Esso consiste nel generare un milione di Float pseudo-casuali, e di scriverli su file sia come Float che come Posit sotto forma di bit, il tutto per evitare di falsare il test a sfavore di questi ultimi, in quanto nel tempo di elaborazione vi sarebbe anche il tempo di conversione.

Una volta acquisiti i dati da file, per ciascun tipo, impiego la funzione `clock_gettime()`, la quale viene richiamata prima e dopo aver finito di calcolare la sigmoide su tutti i dati.

Successivamente ho ripetuto lo stesso esperimento, incrementando gradualmente il numero di elementi, per verificare se l'eventuale margine fosse influenzato dalle dimensioni, nello specifico lo step scelto è stato di 10 mila, con numero massimo di 5 milioni.




Figura 3: "Tempi all'aumentare degli elementi"

### 3.3.2 Parte 1 - Esito

I risultati hanno evidenziato che la funzione, calcolata mediante manipolazione di bit, quindi impiegando solamente la ALU del processore, è più rapida di  $\approx 1.5 - 1.8$  volte su un campione di 1 milione di elementi.

Per quanto riguarda l'incremento, come si può evincere dalla Figura 3, il tempo di elaborazione aumenta linearmente all'aumentare del numero degli elementi in entrambi i casi, di conseguenza possiamo affermare che il vantaggio rimane pressoché costante.

### 3.3.3 Parte 2

In questa seconda parte ho voluto usare come metro di paragone, invece della curva logistica su Float, una sua versione approssimata ottenuta mediante quanto descritto nell'articolo "A Fast, Compact Approximation of the Exponential Function" [3]. In particolare questo algoritmo ci permette di ottenere una approssimazione di  $e^x$ , sfruttando il fatto che i Float, utilizzano una rappresentazione del tipo  $2^x$ . Il vantaggio consiste nel fatto che il tutto è ottenuto operando solamente semplici operazioni sui bit.

La metodologia del test è medesima a prima.

### 3.3.4 Parte 2 - Esito

I risultati mostrano che per calcolare la sigmoide con i Posit ci si impiega in media  $\approx 4.8 - 5$  volte in meno. Di conseguenza nonostante l'aver adoperato questo tipo di approssimazione, risulta essere essere sconveniente l'utilizzo dei Float.

### 3.3.5 Parte 3

L'ultimo confronto che ho voluto eseguire, è stato usando come riferimento una versione della sigmoide che non fa uso di esponenziali  $f(x) = \frac{x}{\sqrt{1+x^2}}$ , quindi in teoria ancora più rapida da calcolare.

Anche in questo caso la metodologia del test è medesima ai precedenti.

### 3.3.6 Parte 3 - Esito

I risultati hanno visto di nuovo i Posit trionfare, questa volta sono risultati essere  $\approx 1.4 - 1.6$  volte più veloci rispetto ai Float.

### 3.3.7 Codice

```
1 //Test per Posit
2 double doTestPosit(unsigned int *posit_array, unsigned long n)
3 {
4     auto p = Posit(32, 0);
5     timespec start, stop;
6     clock_gettime(CLOCK_REALTIME, &start);
7     for(unsigned long i=0; i<n; i++){
8         sigmoid(posit_array[i]);
9     }
10    clock_gettime(CLOCK_REALTIME, &stop);
11    double res = BILLION*( stop.tv_sec - start.tv_sec )
12    + ( stop.tv_nsec - start.tv_nsec );
13    return res;
14 }
15 //Sigmoide su Posit
16 unsigned int sigmoid(unsigned int bits){
17     bits = bits ^ 0x80000000;
18     bits = bits >> 2;
19     return bits;
20 }
21 //Sigmoide Curva Logistica
22 float sigmoid(float &x){
23     return 1/(exp(-x)+1);
24 }
25 //Sigmoide Esponenziale Approssimata
26 float sigmoid(float &x){
27     return 1/(EXP_V(-x)+1);
28 }
29 //Sigmoide Approssimata con Float
30 float sigmoid(float &x){
31     return x/sqrtf((float)(x*x+1));
32 }
33 //Approssimazione Esponenziale
34 #define EXPA (1048576/LN2)
35 #define EXPC 60801
36 #define EXP_V(y) (eco.n.i = EXPA*(y) + (1072693248 - EXPC), eco.d)
```

### 3.4 Conclusioni

I Posit sono stati gli assoluti vincitori sui tempi di calcolo della sigmoide, senza perdere troppo in accuratezza, rendendoli particolarmente interessanti in ambienti in cui ne viene fatto un largo impiego. Inoltre vista la presenza del superesponente, si potrebbe anche pensare di utilizzare meno bit per i dati, non rinunciando eccessivamente sulla precisione o sul range di rappresentabilità.

## 4 Divisione e Moltiplicazione mediante regime

### 4.1 Introduzione

Lavorando con Posit con 0 bit di esponente, il "superesponente"  $(2^{2^{es}})^{regime}$  viene notevolmente semplificato, in quanto  $2^{2^0} = 2 \Rightarrow 2^{regime}$  esattamente come nei Float. L'unica differenza consiste nel fatto che il regime non è un campo a dimensione fissa.

L'idea è stata quella di sfruttare questa caratteristica dei Posit 0, per implementare moltiplicazioni e divisione, per potenze del 2, semplicemente intervenendo sul regime. Il grande vantaggio consiste nel fatto che essendo esso composto da una sequenza di bit uguali, incrementarne o decrementarne il valore è relativamente semplice e poco costoso!

Ad esempio, dato un Posit-0: 0 001 00000<sup>4</sup>, il quale rappresenta +0.25, se volessimo dividerlo per 2, basterebbe aggiungere uno 0 al regime, ottenendo quindi 0 0001 0000<sup>5</sup> = +0.125

### 4.2 Accuratezza

Dopo aver implementato le funzioni che eseguono rispettivamente moltiplicazione e divisione, ne ho voluto testare l'accuratezza confrontando i risultati, utilizzando come riferimento i Double.

Nello specifico ho confrontato il delta fra il riferimento e i risultati ottenuti eseguendo lo stesso calcolo su Posit e Float.

#### 4.2.1 Risultati

Su un campione di 1 milione di numeri non è stata evidenziata alcuna differenza fra i risultati ottenuti con i Float e con i Posit nel 100% dei casi.

Il risultato è giustificabile con il fatto che, eliminando il "superesponente" il Posit diventa un Float con una mantissa a dimensione variabile.

### 4.3 Tempi

Una volta dimostrato che non vi è alcun vantaggio, in termini di accuratezza, ho voluto verificare quanto fosse il guadagno in termini computazionali.

Il test è stato svolto su un campione di 1 milione di elementi, sfruttando la funzione `clock_gettime()`, come già fatto in precedenza.

#### 4.3.1 Risultati

Dai dati emersi i Float risultano essere più veloci di  $\approx 2 - 2.5$  volte rispetto ai Posit nelle divisioni, mentre nelle moltiplicazioni il divario aumenta fino

---

<sup>4</sup>Regime = -2; Mantissa = 0

<sup>5</sup>Regime = -3; Mantissa = 0

a  $\approx 3$  volte.

Per quanto possa sembrare strano ad un primo impatto, un risultato del genere è del tutto normale, in quanto le divisioni e moltiplicazioni, per potenze del 2, sui Float risultano essere ancora più semplici, in quanto basta semplicemente incrementare (o decrementare) l'esponente, il che è ulteriormente facilitato dalla loro natura "statica".

#### 4.3.2 Codice

```
1 //Funzione per calcolare i tempi di esecuzione
2 double doTestPosit(unsigned int *X,unsigned long n)
3 {
4     auto p1 = Posit(32, 0);
5     timespec start, stop;
6
7     clock_gettime( CLOCK_REALTIME, &start );
8     for(unsigned long i=0;i<n;i++){
9         p1.setBits(X[i]);
10        p1.mul_p2(4); //moltiplico per 16
11    }
12
13    clock_gettime( CLOCK_REALTIME, &stop );
14
15    double res = BILLION*( stop.tv_sec - start.tv_sec ) +
16    ( stop.tv_nsec - start.tv_nsec );
17
18    return res;
19
20 }
```



## 5 Conclusioni

Nel complesso i Posit si sono rivelati un'ottima alternativa alle soluzioni attualmente impiegate, soprattutto dal punto di vista della flessibilità, basti pensare all'assenza di under o overflow, e sarebbe davvero interessante vederne una loro implementazione hardware, per poterne testare a pieno le potenzialità senza essere vincolati a delle implementazioni software. Inoltre la sua versione a 0 bit di esponente, ha mostrato caratteristiche davvero particolari, come ad esempio la possibilità di calcolare la sigmoide a costo "nullo", che meriterebbero ulteriori analisi.

## Bibliografia

- [1] Clément Guérin. "*Beyond Floating Point*". URL: <https://github.com/libcg/bfp>.
- [2] John R. Hauser. "*Berkeley SoftFloat*". URL: <http://www.jhauser.us/arithmetic/SoftFloat.html>.
- [3] Nicol N. Scharaudolph. "A fast, Compact Approximation of the Exponential Function". In: (1998).